Institut national universitaire Jean-François Champollion

École d'ingénieurs ISIS

IA HYBRIDE — MINI-PROJET

Rapport de projet — Sujet 1 : dépistage du diabète expliqué

DiabetesCheck AI

Estimer et expliquer le risque de diabète en combinant apprentissage automatique et règles médicales sourcées

Données Pima Indians Diabetes (768 patientes)

AUTEURS

Arthur Prevel | Wiame Bourjila

5e année DSIA — Année universitaire 2026–2027

Octobre 2026

Résumé

Ce rapport porte sur le dépistage du diabète de type 2 à partir de mesures cliniques simples. L'objectif est double : estimer le risque de diabète d'une patiente et fournir une explication vérifiable par un médecin. Nous combinons un modèle d'apprentissage, régression logistique ou XGBoost, avec six règles médicales issues des recommandations de l'ADA, de l'OMS, de l'USPSTF et de l'ESC/ESH. Ces règles sont utilisées en entrée comme variables expertes et en sortie comme garde-fous de la prédiction.

Les expériences portent sur le jeu Pima Indians Diabetes (768 patientes). Les valeurs physiologiquement impossibles sont traitées comme manquantes et imputées sans fuite d'information, et le seuil de décision est choisi sur l'échantillon d'apprentissage afin de garantir un rappel de 80 %. L'évaluation, menée en validation croisée répétée, couvre la performance, la calibration, la cohérence avec les règles, l'explicabilité, la robustesse et le coût.

Les règles ne modifient pas la discrimination (AUC proche de 0,84 avec ou sans règles), mais elles corrigent les prédictions hors distribution, rendent chaque décision traçable et permettent une explication associant contributions SHAP et règles déclenchées. Une contrainte de monotonie imposée à XGBoost réduit fortement les incohérences médicales et améliore légèrement l'AUC. Ces résultats restent limités à une population de femmes Pima de 21 ans et plus.

Mots-clés : IA hybride ; diabète ; dépistage ; règles médicales ; explicabilité ; SHAP ; calibration.

Abstract

This report addresses type 2 diabetes screening from simple clinical measurements. We combine a machine learning model, logistic regression or XGBoost, with six evidence-based medical rules derived from ADA, WHO, USPSTF and ESC/ESH guidelines, used both as expert input features and as output safeguards. On the Pima Indians Diabetes dataset (768 patients), the rules do not change discrimination (AUC close to 0.84), but they correct out-of-distribution predictions, make every decision traceable to a source and support explanations combining SHAP contributions with triggered rules. A monotonicity constraint on XGBoost markedly reduces medically inconsistent predictions and slightly improves the AUC. Results are limited to Pima women aged 21 and over.

Keywords: hybrid AI; diabetes; screening; medical rules; explainability; SHAP; calibration.

Abréviations principales

ADA : American Diabetes Association ; **AUC** : aire sous la courbe ROC ; **ECE** : erreur de calibration attendue ; **HGPO** : hyperglycémie provoquée par voie orale ; **IMC** : indice de masse corporelle ; **KNN** : k plus proches voisins ; **MICE** : imputation multiple par équations chaînées ; **OMS** : Organisation mondiale de la santé ; **SHAP** : SHapley Additive exPlanations ; **USPSTF** : US Preventive Services Task Force.

Table des matières

Résumé **i**

1 Introduction **1**
1.1 Contexte et question clinique 1
1.2 Démarche 1

2 Méthodes **1**
2.1 Données et règles de qualité 1
2.2 Modèles de référence et seuil de décision 1
2.3 Connaissances médicales mobilisées 2
2.4 Architecture hybride 2
2.5 Protocole d'évaluation 3

3 Résultats **3**
3.1 Modèles de référence 3
3.2 Apport des règles : ablation 4
3.3 Calibration et cohérence 4
3.4 Cas difficiles 4
3.5 Explication pour une patiente 5
3.6 Analyse d'erreurs 5

4 Discussion **5**
4.1 Interprétation des résultats 5
4.2 Limites 6
4.3 Conclusion et perspectives 6

Déclaration d'utilisation d'un assistant de code **6**

Références bibliographiques **6**

Liste des tableaux

1 Règles médicales mobilisées et fréquence dans l'échantillon d'apprentissage 2
2 Effet du seuil de décision sur l'échantillon de test (54 malades) 3
3 Ablation : écart d'AUC par rapport à la référence (validation croisée 5 × 5) 4
4 Calibration et cohérence monotone des modèles (validation croisée) 4
5 Origine des erreurs de la version complète (moyenne sur 5 répétitions, 768 patientes) 5

Liste des figures

1 Architecture hybride : les règles médicales encadrent le modèle avant et après la prédiction 3

1 Introduction

1.1 Contexte et question clinique

Le diabète de type 2 évolue souvent de manière silencieuse pendant plusieurs années, et son dépistage repose sur des mesures simples comme la glycémie après une charge orale en glucose, l'indice de masse corporelle ou l'âge. Un outil d'aide au dépistage doit donc répondre à deux exigences : estimer correctement le risque, et justifier cette estimation de façon qu'un médecin puisse la contrôler. Un modèle d'apprentissage seul satisfait la première exigence mais difficilement la seconde, tandis qu'un ensemble de règles cliniques est vérifiable mais peu nuancé.

La question traitée est la suivante : *l'ajout de règles médicales sourcées à un modèle d'apprentissage améliore-t-il l'estimation du risque de diabète et son explicabilité, et dans quelles conditions ?*

1.2 Démarche

Nous construisons d'abord une référence non hybride, fondée sur une régression logistique et sur un modèle de gradient boosting. Nous construisons ensuite une version hybride dans laquelle les règles interviennent à deux niveaux : en entrée, sous forme de variables expertes, et en sortie, sous forme de règles qui encadrent la probabilité prédite. Les deux versions sont comparées selon un protocole commun comprenant une ablation, des cas difficiles et une analyse d'erreurs attribuant chaque erreur à sa brique. Le code est disponible dans le notebook `DiabetesCheck_Hybride_v2.ipynb` du dépôt du projet.

2 Méthodes

2.1 Données et règles de qualité

Nous utilisons le jeu Pima Indians Diabetes, diffusé par l'UCI et disponible sur OpenML (identifiant 37) [6]. Il décrit 768 femmes d'origine Pima âgées d'au moins 21 ans, dont 268 (34,9 %) sont diabétiques, au moyen de huit variables : nombre de grossesses, glycémie deux heures après une charge orale de 75 g de glucose (mg/dL), pression artérielle diastolique, pli cutané tricipital, insulinémie, IMC, score d'antécédents familiaux et âge.

Une glycémie, une pression, un pli cutané, une insulinémie ou un IMC nuls sont physiologiquement impossibles ; ces valeurs sont donc recodées comme manquantes. Elles concernent surtout l'insulinémie (48,7 %) et le pli cutané (29,6 %), contre moins de 5 % pour les autres variables. Supprimer les observations incomplètes aurait réduit l'échantillon de moitié ; nous avons donc imputé ces valeurs. Les données sont séparées en un échantillon d'apprentissage (614 patientes) et un échantillon de test (154 patientes), de façon stratifiée et avant tout traitement. La standardisation et l'imputation sont intégrées à un pipeline afin d'être apprises uniquement sur les données d'entraînement de chaque pli [12].

Trois méthodes d'imputation ont été comparées en validation croisée à cinq plis avec une régression logistique : la médiane (AUC = 0,843 ± 0,029), les k plus proches voisins avec k = 5 (0,842 ± 0,029) et l'imputation multiple par équations chaînées, MICE [7] (0,843 ± 0,030). Les écarts étant très inférieurs à la variabilité entre plis, nous avons retenu KNN, qui exploite les autres mesures de la patiente. Une imputation conditionnelle à la classe a également été testée puis écartée : elle n'atteint 0,832 d'AUC sur le test que si l'étiquette du test est utilisée pour l'imputation, ce qui constitue une fuite d'information, et retombe à 0,788 dans une version applicable à une nouvelle patiente.

2.2 Modèles de référence et seuil de décision

La référence non hybride repose sur une régression logistique et sur XGBoost [11] (300 arbres de profondeur 3, taux d'apprentissage de 0,05). Une forêt aléatoire a été évaluée à titre de comparaison mais n'a pas été conservée, ses performances étant intermédiaires. En contexte de dépistage, une malade non détectée est plus préjudiciable qu'une fausse alerte. Le seuil de décision est donc choisi sur l'échantillon d'apprentissage, à partir de prédictions hors-pli : il s'agit du plus grand seuil garantissant un rappel d'au

moins 80 %. Ce critère conduit à un seuil de 0,29 pour la régression logistique et de 0,24 pour XGBoost. Le rééquilibrage par SMOTE [9] a été comparé à cette stratégie à rappel égal ; il ne réduit pas le taux de fausses alertes (30,5 % contre 32,0 %) et ne modifie pas le score de Brier (0,176). Il n'a donc pas été retenu.

2.3 Connaissances médicales mobilisées

Dans ce jeu de données, la glycémie est mesurée deux heures après une charge en glucose. Les seuils applicables sont donc ceux de l'hyperglycémie provoquée par voie orale, 140 et 200 mg/dL, et non ceux de la glycémie à jeun, 100 et 126 mg/dL [1, 2]. Le tableau 1 présente les six règles retenues et leur fréquence dans l'échantillon d'apprentissage.

Tableau 1 – Règles médicales mobilisées et fréquence dans l'échantillon d'apprentissage.

Règle	Condition	Signification	Source	Patientes	Diabète si vraie / sinon
R1	Glycémie ≥ 200	Diabète	ADA 2024 [1]	0	—
R2	140 ≤ glycémie < 200	Intolérance au glucose	ADA 2024 ; OMS 2006 [1, 2]	156	71 % / 23 %
R3	IMC ≥ 30	Obésité	OMS [3]	379	46 % / 17 %
R4	IMC ≥ 25 et âge ≥ 35	Dépistage recommandé	USPSTF 2021 [4]	202	54 % / 25 %
R5	Pression diastolique ≥ 90	Hypertension	ESC/ESH 2018 [5]	44	50 % / 34 %
R6	Glycémie < 140, IMC < 25, âge < 35	Aucun critère de dépistage	Dérivée de [1, 4]	59	2 % / 38 %

Glycémie en mg/dL mesurée 2 h après une charge orale de 75 g de glucose ; IMC en kg/m^2 ; pression en mmHg.

La règle R1 ne se déclenche jamais, la glycémie maximale observée étant de 199 mg/dL ; elle est conservée pour les cas hors distribution. R6 n'est pas une recommandation officielle : elle regroupe les patientes qui ne remplissent aucun critère de dépistage de l'USPSTF [4] et peut, à ce titre, conduire à une fausse rassurance.

2.4 Architecture hybride

La figure 1 résume l'architecture. Les six règles sont d'abord ajoutées sous forme de variables binaires aux huit variables d'origine, après l'imputation, afin de ne pas modifier les distances utilisées par KNN. Après la prédiction, deux règles encadrent la probabilité : R1, critère diagnostique, impose un risque d'au moins 0,9, et R6 plafonne le risque à 0,1, valeur fixée empiriquement (une diabétique parmi les 59 patientes concernées de l'échantillon d'apprentissage). Pour chaque patiente, la source de la décision est conservée : le modèle, ou la règle qui a modifié la prédiction. Une troisième forme de connaissance a été testée sur XGBoost : une contrainte de monotonie imposant que le risque ne diminue pas lorsque la glycémie ou l'IMC augmente.

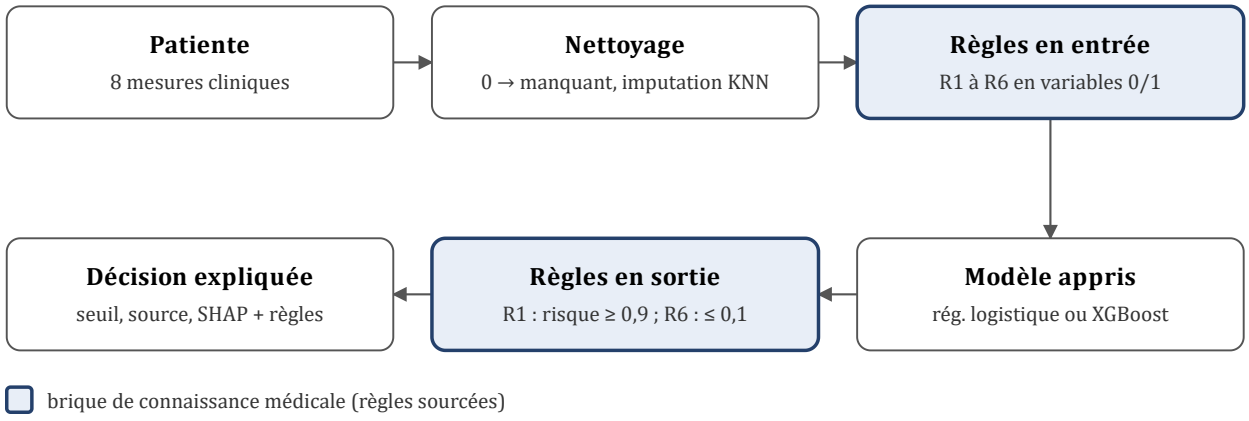


Figure 1 – Architecture hybride : les règles médicales encadrent le modèle avant et après la prédiction.

L'explication individuelle s'appuie sur les valeurs de SHAP [8], calculées de manière exacte pour la régression logistique avec règles. La contribution d'une règle est regroupée avec celle de la variable qu'elle découpe, par exemple R2 avec la glycémie, afin d'éviter des messages contradictoires. Ces contributions sont présentées avec les règles déclenchées et leur source, ainsi qu'un court texte produit par gabarit. Ce choix, plutôt qu'un modèle de langage, garantit un texte déterministe, vérifiable et sans recommandation inventée.

2.5 Protocole d'évaluation

L'échantillon de test ne comptant que 154 patientes, les mesures principales sont obtenues par validation croisée stratifiée 5 × 5 sur les 768 patientes. Les écarts entre versions sont des différences appariées, accompagnées d'intervalles de confiance à 95 % estimés par bootstrap (1 000 tirages). Sept dimensions de la grille d'évaluation sont couvertes : la performance (AUC, F1, rappel), la calibration (ECE sur dix intervalles, courbes de fiabilité et recalibration par température [10]), la cohérence avec les règles et la monotonie, la fidélité et l'explicabilité des explications, la robustesse (cas difficiles et tranches d'âge) et le coût de calcul.

3 Résultats

3.1 Modèles de référence

En validation croisée sur l'échantillon d'apprentissage, la régression logistique obtient une AUC de 0,842, la forêt aléatoire de 0,836 et XGBoost de 0,819 ; sur le test, l'ordre s'inverse (0,814, 0,812 et 0,832). Ces écarts, inférieurs à 0,03, ne permettent pas de départager les modèles. Les coefficients standardisés de la régression logistique confirment le poids de la glycémie (1,17) et de l'IMC (0,70), tandis que l'insulinémie, le pli cutané et la pression ont des coefficients proches de zéro. Le tableau 2 montre l'effet du seuil de décision sur le test.

Tableau 2 – Effet du seuil de décision sur l'échantillon de test (54 malades).

Modèle	Seuil	Rappel [IC 95 %]	Malades manquées	Fausses alertes
Régression logistique	0,50	0,48 [0,35 ; 0,61]	28	18
Régression logistique	0,29	0,80 [0,67 ; 0,88]	11	31
XGBoost	0,50	0,69 [0,55 ; 0,79]	17	16
XGBoost	0,24	0,89 [0,78 ; 0,95]	6	32

Intervalles de confiance de Wilson. Le test compte 154 patientes, dont 54 malades.

Au seuil de 0,5, la régression logistique ne détecte que 48 % des malades. Le seuil choisi sur l'apprentissage porte le rappel à 0,80 pour la régression logistique, conformément à la cible, et à 0,89

pour XGBoost, au prix d'environ 31 fausses alertes pour 100 patientes non malades. Les intervalles de confiance restent larges, le test ne comptant que 54 malades.

3.2 Apport des règles : ablation

En validation croisée, l'AUC est de 0,836 pour la régression logistique et de 0,825 pour XGBoost, quelle que soit la version. Le tableau 3 présente l'écart apparié obtenu en ajoutant chaque brique.

Tableau 3 – Ablation : écart d'AUC par rapport à la référence (validation croisée 5 × 5).

Brique ajoutée	Régression logistique	XGBoost
Règles en entrée	−0,0025 [−0,011 ; +0,006]	+0,0021 [−0,001 ; +0,005]
Règles en sortie	+0,0013 [+0,0003 ; +0,0029]	non significatif
Contrainte de monotonie	—	+0,0086 [+0,0018 ; +0,0161]

ΔAUC moyen et intervalle de confiance à 95 % par bootstrap apparié (1 000 tirages).

Les règles en entrée n'ont pas d'effet démontrable. Sur le seul échantillon de test, nous avions observé des écarts de signe opposé (+0,007 et −0,003), ce qui illustre l'instabilité d'une évaluation fondée sur 154 patientes. Les règles en sortie produisent un effet détectable mais négligeable pour la régression logistique, attribuable à R6. La contrainte de monotonie est la seule brique qui améliore nettement la discrimination de XGBoost.

3.3 Calibration et cohérence

Tableau 4 – Calibration et cohérence monotone des modèles (validation croisée).

Modèle	ECE	ECE après température	Glycémie +10 mg/dL	IMC +3 kg/m²	AUC
Régression logistique	0,036	0,030	0,1 %	0,3 %	0,836
XGBoost	0,061	0,032	20,3 %	37,5 %	0,825
XGBoost monotone	—	—	8,9 %	10,7 %	0,828

Les colonnes « Glycémie +10 » et « IMC +3 » donnent la part des patientes dont le risque prédit diminue lorsque la variable augmente.

La régression logistique est bien calibrée (ECE = 0,036), alors que XGBoost surestime la confiance de ses prédictions (ECE = 0,061). La recalibration par température (T = 1,47) ramène son ECE à 0,032 sans modifier l'AUC. Les règles n'ont pas d'effet sur la calibration. En termes de cohérence, 99,2 à 99,4 % des patientes relevant de R6 sont déjà prédites non diabétiques sans règle, et 94 à 96 % des patientes relevant de R2 sont classées à risque. L'analyse de monotonie révèle en revanche une incohérence importante de XGBoost : une hausse de 10 mg/dL de la glycémie fait baisser le risque prédit chez 20,3 % des patientes. La contrainte de monotonie réduit cette proportion à 8,9 %. Pour la régression logistique, les règles en entrée font passer les violations de 0,1 % à 2,6 %, vraisemblablement parce que R2 est définie sur l'intervalle 140–199 mg/dL et cesse de s'appliquer au-delà de 200 mg/dL.

3.4 Cas difficiles

Lorsque l'apprentissage est restreint à 50 patientes, la régression logistique conserve une AUC de 0,784, contre 0,734 pour XGBoost. Les règles en entrée n'apportent pas un gain plus important lorsque les données sont rares (+0,005 à n = 50 et +0,006 à n = 400 pour la régression logistique), ce qui infirme notre hypothèse initiale. Pour les patientes relevant de R6, la règle confirme une prédiction déjà faible et en fournit la source.

Le cas hors distribution est plus démonstratif. Pour une patiente fictive de 25 ans, d'IMC 23 et de glycémie 250 mg/dL, XGBoost ne prédit qu'un risque de 0,56, ses arbres n'ayant jamais observé de glycémie supérieure à 199 mg/dL. La règle R1 corrige ce risque à 0,90 et cite sa source. La régression logistique, qui extrapole linéairement, prédisait déjà 0,93.

Le jeu est par ailleurs déséquilibré selon l'âge : 58 % des patientes du test ont entre 21 et 30 ans, et seules 20 % d'entre elles sont malades. Au seuil choisi, le rappel n'est que de 0,61 à 0,67 dans cette tranche, contre 0,85 à 1,00 au-delà de 30 ans, et les règles ne réduisent pas cet écart.

3.5 Explication pour une patiente

La somme du risque moyen et des contributions SHAP retrouve la sortie du modèle à 10^{-15} près, ce qui garantit la fidélité de l'explication. Pour une patiente du test dont le risque prédit est de 99 %, l'explication produite est la suivante :

> *Risque estimé : 99 % (au-dessus du seuil de dépistage de 29 %). Ce qui augmente le risque : la glycémie à 2 h (180 mg/dL), l'IMC (59,4 kg/m²) et les antécédents familiaux (2,42). Règles déclenchées : R2, intolérance au glucose [ADA 2024 ; OMS 2006] ; R3, obésité [OMS]. À confirmer par un examen médical.*

Le médecin peut ainsi vérifier chaque élément à partir des mesures de la patiente et des recommandations citées.

3.6 Analyse d'erreurs

Tableau 5 – Origine des erreurs de la version complète (moyenne sur 5 répétitions, 768 patientes).

Origine de l'erreur	Régression logistique	XGBoost
Modèle (variables insuffisantes)	111,6	124,8
Seuil bas (fausses alertes acceptées)	74,2	76,6
Introduites par les règles en entrée	22,2	7,6
Corrigées par les règles en entrée	18,4	8,4
Donnée manquante imputée	1,8	1,8
Introduites par les règles en sortie	0	0
Total des erreurs (référence → version complète)	206,0 → 209,8	211,8 → 210,8

Chaque erreur de la version complète est rattachée à la brique qui l'a produite. Les règles en entrée introduisent à peu près autant d'erreurs qu'elles en corrigent, ce qui est cohérent avec l'absence d'effet mesuré lors de l'ablation, et les règles en sortie n'en introduisent aucune. La majorité des erreurs relève du modèle lui-même, et environ 75 fausses alertes résultent du choix délibéré d'un seuil bas. Les faux négatifs les plus marqués concernent des femmes jeunes (âge médian de 29 ans, contre 37 ans pour les malades détectées) dont la glycémie est inférieure à 110 mg/dL : aucune des huit variables ne permet de les distinguer.

4 Discussion

4.1 Interprétation des résultats

Les règles médicales ne rendent pas le modèle plus discriminant, car la glycémie et l'IMC, sur lesquels reposent la plupart des règles, sont déjà exploités par les modèles. Leur intérêt se situe ailleurs. Elles protègent le système dans les zones où les données manquent, comme le montre le cas d'une glycémie de 250 mg/dL, rendent chaque décision traçable jusqu'à une recommandation et produisent une explication vérifiable. Leur coût est négligeable : environ 15 ms supplémentaires pour prédire 154 patientes.

La connaissance la plus utile s'est révélée être une contrainte de forme plutôt qu'un seuil : la monotonie corrige une incohérence médicale de XGBoost tout en améliorant sa performance. Dans ce contexte, la régression logistique avec règles constitue le meilleur compromis. Elle est aussi performante que XGBoost en validation croisée, mieux calibrée, monotone, plus stable lorsque les données sont rares et directement explicable.

4.2 Limites

Les résultats portent sur une population très particulière, des femmes Pima d'au moins 21 ans, et ne peuvent pas être généralisés à d'autres populations. Le test ne compte que 154 patientes, et les intervalles bootstrap ont été estimés sur une seule répétition. Plusieurs paramètres relèvent de choix de conception : le rappel cible de 80 %, les valeurs 0,9 et 0,1 des règles en sortie et la règle R6, qui n'est pas issue d'une recommandation. Enfin, les jeunes malades restent mal détectées, ce que les règles ne corrigent pas. Cet outil est un exercice d'aide au dépistage et ne constitue pas un dispositif de diagnostic.

4.3 Conclusion et perspectives

Ce travail montre qu'une architecture hybride n'améliore pas nécessairement la performance moyenne, mais qu'elle apporte des garanties de sécurité, de cohérence et d'explicabilité qu'un modèle seul ne fournit pas. Plusieurs pistes prolongent ce travail : remplacer la bande R2 par la condition « glycémie ≥ 140 mg/dL » afin de préserver la monotonie, ajouter une règle de sortie fondée sur R2, choisir à nouveau le seuil de XGBoost après recalibration et valider l'approche sur un autre jeu de données.

Déclaration d'utilisation d'un assistant de code

Conformément à la consigne, nous signalons avoir utilisé ponctuellement l'assistant Claude (Anthropic) pour l'écriture de certaines parties du code, la vérification de points techniques, notamment la fuite d'information et le choix du seuil, ainsi que pour la reformulation de passages du rapport. La conception, la vérification des résultats et leur interprétation relèvent des auteurs. Cet usage est également mentionné dans le README du dépôt.

Références bibliographiques

[1] American Diabetes Association Professional Practice Committee. 2. Diagnosis and classification of diabetes: *Standards of Care in Diabetes—2024*. Diabetes Care, 47(Suppl. 1) : S20–S42, 2024.

[2] World Health Organization, International Diabetes Federation. *Definition and diagnosis of diabetes mellitus and intermediate hyperglycaemia*. Genève, WHO, 2006.

[3] World Health Organization. *Obesity: preventing and managing the global epidemic*. WHO Technical Report Series 894, Genève, 2000.

[4] US Preventive Services Task Force. Screening for prediabetes and type 2 diabetes: US Preventive Services Task Force recommendation statement. JAMA, 326(8) : 736–743, 2021.

[5] B. Williams, G. Mancia et al. 2018 ESC/ESH guidelines for the management of arterial hypertension. European Heart Journal, 39(33) : 3021–3104, 2018.

[6] J. W. Smith, J. E. Everhart, W. C. Dickson, W. C. Knowler, R. S. Johannes. Using the ADAP learning algorithm to forecast the onset of diabetes mellitus. Proceedings of the Symposium on Computer Applications in Medical Care, p. 261–265, 1988.

[7] S. van Buuren, K. Groothuis-Oudshoorn. mice: Multivariate imputation by chained equations in R. Journal of Statistical Software, 45(3) : 1–67, 2011.

[8] S. M. Lundberg, S.-I. Lee. A unified approach to interpreting model predictions. Advances in Neural Information Processing Systems 30, 2017.

[9] N. V. Chawla, K. W. Bowyer, L. O. Hall, W. P. Kegelmeyer. SMOTE: synthetic minority over-sampling technique. Journal of Artificial Intelligence Research, 16 : 321–357, 2002.

[10] C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger. On calibration of modern neural networks. Proceedings of the 34th International Conference on Machine Learning, 2017.

[11] T. Chen, C. Guestrin. XGBoost: a scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD Conference on Knowledge Discovery and Data Mining, p. 785–794, 2016.

[12] F. Pedregosa et al. Scikit-learn: machine learning in Python. Journal of Machine Learning Research, 12 : 2825–2830, 2011.